

企业文档处理智能体 — 技术方案文档

版本: v2 (Agent 架构) · 分支: feat/agent-v2 · 状态: 开发中 (OCR 真实联调待 9052)
面向对象: 团队同事 / 评审

1. 项目目标

构建一个 **企业单据处理智能体 (Chatbot)**，覆盖"识别 → 人工校验 → 入库 → 统计问答 → 可视化"完整链路:


- 用户上传**支票/销售单据图片**，系统自动结构化识别
- 识别结果**人工可改** (模型准确率 ~80%，Agent 需要 100% 准确数据)
- 多张图数据入库，供**高效检索与统计** (避免全量喂给大模型烧 token、效果差)
- 统计结果可**绘制图表**
- 后续能力**可插拔扩展**

1.1 目标用户链路

上传图片 → OCR识别 → 人工核对/修改 → 确认入库 → 提问统计 → 图表展示

2. 总体架构

核心思想: 以 Agent 为中心 (而非多个独立服务)。用 LangChain 搭建 DeepSeek LLM 智能体，为其"加装"一组 Tool，每个 Tool 补齐 DeepSeek / 基础模型的一项短板。



2.1 为什么是 4 个 Tool（每个补一个短板）

Tool	短板	解决方案	关键技术
OCR	DeepSeek 是"盲"的，无法看图	InternVL 微调模型识别图片	InternVL3 @ 9052（OpenAI 兼容接口）
Correct	OCR 准确率仅 ~80%，Agent 需要准确数据	界面上人工核对/修改识别结果	SQLite 行级状态机 + Web 表格编辑
RAG	多图全量喂 DeepSeek 费 token 且统计差	数据入库，按需检索/聚合	SQLite 过滤查询 + 统计聚合
Plot	统计数字不直观	绘制统计图	matplotlib → PNG

后续需要新能力（发票类目、合同、导出等）时，在 Agent 中**注册新 Tool 即可扩展**。

3. 模块设计

3.1 目录结构

```
enterprise_ocr_service/
├─ config.py           # .env 加载(OCR 端点 / DeepSeek key / 模型参数)
├─ agent/
│   ├─ llm.py          # DeepSeek LLM 封装(langchain-deepseek ChatDeepSeek)
│   └─ agent.py         # AgentExecutor + 8 个工具注册 + 对话编排
├─ tools/              # 每个工具独立模块(可插拔)
│   ├─ ocr_client.py    # InternVL 客户端：9052 调用 + CSV 解析(纯 httpx)
│   ├─ ocr_tool.py      # Tool1: 识别图片 → 入库待确认
│   ├─ correct_tool.py  # Tool2: 列单据/看行/改行/确认
│   ├─ rag_tool.py      # Tool3: 检索(rag_query) + 聚合(rag_summarize)
│   └─ plot_tool.py     # Tool4: 柱状/饼图 → charts/*.png
├─ db/
│   ├─ database.py      # SQLite 连接/初始化(标准库 sqlite3, WAL)
│   ├─ schema.py        # 建表 DDL
│   └─ crud.py          # 数据操作(用户友好键 desc/date/from/sum)
├─ web/
│   └─ main.py          # FastAPI 单页(上传/修改/问答/图表)
├─ run_web.py          # 启动入口 (127.0.0.1:8100)
├─ data/               # agent.db + 上传图片(本地, gitignore)
├─ charts/             # Plot tool 输出 PNG
└─ tests/test_agent_v2.py # db + tools 单元测试
```

3.2 数据模型 (SQLite)

documents（每张上传图片）：

列	说明
id	主键
file_name	源文件名（唯一，作为图级标识）
sha256	可选，用于去重
uploaded_at	上传时间
status	`recognition_pending` / `rows_inserted`

ocr_rows（每张图识别出的行数据）：

列	说明
id	主键
doc_id	→ documents.id（外键，级联删除）
seq	行号
desc / date / from / item / amount / price / tax / sum	8 列识别字段
status	**pending（待确认） / confirmed（已确认）**
modified_by / modified_at	人工修改留痕

关键设计：**只有 confirmed 的行才进入 RAG / 统计**。Agent 回答时若数据未确认，会如实说明是“待确认草稿”。人工确认前，识别错误不会污染统计结果。

3.3 Tool1 — OCR (InternVL)

- **模型端点**：`http://127.0.0.1:9052/v1/chat/completions`，`model=internvl3`

(`/v1/models` 只显示 `gpt-3.5-turbo`，实际必须用 `internvl3`)

- **Prompt** (S1 真机实测固化)：使用**中英语义引导**而非纯英文 key ——

纯英文 `from` 会被模型错认成日期（实测输出幻觉日期）；中英混写 `from(发货公司/源公司)` 后识别正确。

- **输出**：8 列 `desc,date,from,item,amount,price,tax,sum`（与训练标注一致）
- 识别结果直接写入 SQLite，状态 = `pending`；同图重复识别会先删旧行再插入（覆盖语义）

3.4 Tool2 — Correct (人工修改)

提供 4 个子工具，Web 表格编辑与 Agent 共用同一数据层：

- `correct_list_docs` 列出所有单据及确认进度
- `correct_show_rows(file_name)` 查看某图识别行（含行 id 与状态）
- `correct_update_row(row_id, fields)` 修改单行字段（白名单校验）
- `correct_confirm(file_name, reviewer)` 确认整图全部行（进入统计口径）

3.5 Tool3 — RAG (检索与统计)

- `rag_query(query, top_k)`：对已确认行做关键词检索（商品/公司/日期/文件名），返回明细
- `rag_summarize(group_by, filter)`：按 item/desc/date 聚合（数量、金额小计），

- 因为数据已入库并确认，Agent 只把**命中结果**喂给 DeepSeek —— 省 token 且结果可靠

3.6 Tool4 — Plot (可视化)

- `plot_chart(group_by, chart_type, filter)` : matplotlib 生成 PNG 到 `charts/`
- 支持 bar (柱状) / pie (饼图) ; 中文字体自动探测 (SimHei / Microsoft YaHei)
- Web 端通过 `/charts/{file}` 展示

3.7 Agent 中枢

- **LLM**: DeepSeek `deepseek-chat` (langchain-deepseek 官方接入)
- **编排**: `AgentExecutor + create_tool_calling_agent` (tool-calling 自动决策)
- **系统提示**: 告知 Agent 何时用哪个 Tool、确认状态语义、禁止编造数据
- **可扩展**: 新增能力 = 新增一个 `@tool` 函数并加入列表即可

4. 关键技术结论 (实测沉淀)

1. **InternVL 输出契约 = 训练 8 列**; prompt 需中英语义引导, 纯英文 key 会把 `from` 认成日期
2. **识别数据必须人工确认后才进统计**: 模型有幻觉/重复行 (如一张图 13 行明细实为 3 种商品), 草稿不能直接用于统计
3. **单槽 llama.cpp 一次只处理一个请求**: 一张图约 20~60s, 长 prompt 会卡服务 (曾复现读超时)
4. **langchain 1.x 注意**: `AgentExecutor` 在 `langchain_classic.agents` (`create_tool_calling_agent` 同处) ;

纯 `langchain.agents` 走新 `create_agent` API

1. **matplotlib 中文**需显式指定中文字体, 否则图表乱码
2. 本项目 PyPI 直连不通, 统一用清华源 `-i https://pypi.tuna.tsinghua.edu.cn/simple`

5. 运行与联调

5.1 依赖安装

```
pip install -i https://pypi.tuna.tsinghua.edu.cn/simple langchain langchain-deepseek ^
langchain-classic fastapi uvicorn python-multipart httpx matplotlib
```

5.2 环境变量 (.env)

```
OCR_BASE_URL=http://127.0.0.1:9052/v1
OCR_MODEL=internv13
DEEPSEEK_API_KEY=sk-xxx          # platform.deepseek.com
```

5.3 启动

```
# 1) 先确保 InternVL 9052 在线(隧道/服务)
# 2) 启动 Web(单页集成了全部功能)
python run_web.py # http://127.0.0.1:8100
```

5.4 API 一览 (FastAPI, /docs 有 Swagger)

方法 & 路径	用途
POST `/api/ocr`	multipart 上传图片 → 识别 → 入库待确认
GET `/api/docs`	单据列表 (行数/确认状态)
GET `/api/docs/{name}`	某图识别行
POST `/api/rows/{id}`	人工修改某行
POST `/api/confirm`	确认某图全部行
POST `/api/agent`	智能体问答 (会按需调 Tool)
POST `/api/chart`	画统计图
GET `/charts/{file}`	图表文件
GET `/api/stats`	总览

6. 测试与质量

- 单元测试 (tests/test_agent_v2.py) : db CRUD、Correct/RAG Tool 逻辑

(不依赖真实模型/网络, 可离线跑)

- ruff 静态检查: 通过

```
pytest tests -q
ruff check db agent tools web config.py run_web.py
```

7. 当前进度与待办

项	状态
SQLite 数据层 (doc + rows / 状态机)	✓
Tool1 OCR (客户端 + 入库)	✓ 代码就绪, **待 9052 真实联调**
Tool2 Correct	✓
Tool3 RAG	✓
Tool4 Plot	✓
Agent 中枢 (8 工具)	✓
Web 单页面	✓
端到端真实联调 (上传→改→确认→问答→图)	⌚ 待 9052 在线
发票等第二类目扩展	📅 规划中 (数据/模型未提供)

8. 版本演进 (git)

master

旧版: 双 FastAPI 服务(8000 OCR + 8100 rag/CSV) ← 已归档, 保留

feat/agent-v2

新版: Agent 架构(本文档描述) ← 当前开发分支

如需查看旧版实现细节, 切到 master 分支阅读。